

Ilościowa analiza typologiczna języków posługujących się alfabetem łacińskim z wykorzystaniem modeli n -gramowych*

Adam Karol Drażyk¹

¹Faculty of Applied Mathematics, Silesian University of Technology, Kaszubska 23, 44100 Gliwice, POLAND

Abstract

Lingwistyka typologiczna coraz częściej odchodzi od ręcznej analizy danych na rzecz algorytmów opartych na przetwarzaniu ogromnych korpusów tekstowych. Niniejsza praca prezentuje podejście oparte na analizie surowych korpusów na poziomie n -gramów znakowych. Celem badań było sprawdzenie czy proste algorytmy klasyfikacyjne są w stanie odzwierciedlić naturalny podział języków na rodziny językowe. Analizie poddano 32 korpusy językowe, składające się z 15 000 najczęściej występujących słów z bazy OpenSubtitles. Wykorzystując model Word2Vec osadzono 3-gramy znakowe w wysoce wymiarowej przestrzeni wektorowej, na ich podstawie wyznaczono centroidy słów, a następnie całych języków. Po osadzeniu języków dokonano ich klasteryzacji wykorzystując algorytm Affinity Propagation, posługując się podobieństwem cosinusowym między kolejnymi parami języków. Klasteryzacja poskutkowała utworzeniem 6 złożonych klastrow, które poddano ilościowej analizie morfologicznej w celu wyekstrahowania najważniejszych charakterystyk takich jak entropia 2-gramowa, średnia maksymalna długość zbitki spółgłoskowej, procentowy udział samogłosek czy wyznaczenie najczęściej występujących afiksów. Porównanie danych z innymi źródłami potwierdziło poprawne odzwierciedlenie istniejących grup językowych, takich jak grupa germańska, romańska, słowiańska czy austronezyjska. Uzyskane rezultaty dowodzą, że modele oparte na prostej analizie n -gramowej są zdolne do uchwycenia subtelnych różnic ortograficznych, leksykalnych i morfologicznych między językami różnego pochodzenia.

Keywords

latin-script languages, morphological analysis, affinity propagation, word2vec, ap, language clustering, affixes, ngrams

1. Wstęp

Problem grupowania języków sięga już starożytności, Rzymianie przykładowo wierzyli, że łacina wywodzi się bezpośrednio z greki [1]. Pierwsze próby ścisłego podziału języków pojawiły się w XIV wieku między innymi za sprawą Dantego Alighieri, który w swoim traktacie *De vulgari eloquentia* podzielił dialekty romańskie na trzy grupy, na podstawie słowa oznaczającego *tak*: grupy *oïl*, grupy *oc* oraz grupy *si* [2]. W 1599 roku holenderski uczony Joseph Scaliger sklastrował języki na cztery główne rodziny, na podstawie słowa, które oznaczało *Boga*: języki romańskie (*Deus*), języki greckie (*Theos*), języki germańskie (*Godt*) oraz języki słowiańskie (*Bog*) [3].

Współcześnie przy klastrowaniu języków odchodzi się od ręcznej analizy pojedynczych słów

✉ ad315968@student.polsl.pl (A. K. Drażyk)



© 2026 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).



CEUR Workshop Proceedings (CEUR-WS.org)

na rzecz metod obliczeniowych i przetwarzania ogromnych korpusów językowych. Jedną z prężnie rozwijających się dziedzin zajmujących się analizą języka jest NLP (*Natural Language Processing*), w której algorytmy uczenia maszynowego są wykorzystywane, do rozumienia, generowania oraz klasyfikowania tekstu. Jedną z metod klastrowania języków jest wyznaczanie średniej odległości Levenshteina pomiędzy odpowiadającymi sobie słowami, tak jak w pracy M. Serva i F. Petroni *Indo-European languages tree by Levenshtein distance* [4], algorytm pomyślnie sklasyfikował języki, jednak podejście to wymaga ręcznego zestawiania słowników, ponieważ algorytm operuje na parach odpowiadających sobie słów. Inną powszechnie stosowaną metodą do grupowania języków są algorytmy k -średnich, główną wadą tego rozwiązania jest jednak fakt, że wymuszanie a priori liczby k klastrów znacząco wpływa na wynik grupowania, co często pozwala na sztuczne osiągnięcie założonych rezultatów [5]. Współczesną alternatywą są modele transformatorowe, takie jak mBERT, jednak ich wysoka złożoność obliczeniowa oraz skupienie na reprezentacji semantycznej sprawiają, że mogą one zacierać subtelne cechy morfologiczne [6]. P. Bojanowski w artykule *Enriching word vectors with subword information* wykazuje, że wektoryzacja na poziomie n -gramów znakowych pozwala algorytmom na uchwycenie morfologii słów [7].

W niniejszej pracy zaproponowano połączenie algorytmów Word2Vec [8] oraz Affinity Propagation [9] w celu stworzenia w pełni zautomatyzowanego i nienadzorowanego algorytmu klasteryzacji i analizy typologicznej. Celem badań było zweryfikowanie, czy prosty model oparty na wektoryzacji 3-gramów znakowych potrafi zrekonstruować podziały lingwistyczne. Wykorzystano w tym celu reprezentację centroidów dla 32 języków, których materiał badawczy stanowiły korpusy z bazy OpenSubtitles [10]. Połączenie wektoryzacji Word2Vec z algorytmem Affinity Propagation pozwoliło na wyłonienie naturalnych grup językowych na podstawie czysto statystycznej dystrybucji tekstowej.

2. Metodologia

Analizie poddajemy 32 korpusy językowe, z których każdy składa się z dokładnie 15 000 najczęściej występujących słów. Korpus opiera się na surowych formach tekstowych, co pozwala na uchwycenie wzorców morfologicznych poszczególnych języków. Ograniczamy się do 15 000 słów w celu odsiania szumu statystycznego. Podstawę materiału badawczego stanowią pozyskane frekwencyjne listy z bazy OpenSubtitles [10]. Wykorzystanie danych opartych na transkrypcjach dialogów filmowych pozwala na wierne odzwierciedlenie naturalnej, codziennej mowy.

Każdy z korpusów poddajemy procesowi normalizacji, który obejmuje usunięcie cyfr, białych znaków oraz znaków interpunkcyjnych. W ramach preprocessingu do każdego słowa dodajemy znaki # na jego początku i końcu, w celu oznaczenia granic słowa. Następnie każde słowo z analizowanych korpusów dzielimy na 3-gramy, które zebrano we wspólnym zbiorze treningowym D .

Zbiór treningowy D poddajemy embeddingowi z wykorzystaniem modelu Word2Vec [8]. Model trenujemy przy użyciu metody Skip-gram. Wektory osadzamy w 300-wymiarowej rzeczywistej przestrzeni wektorowej $\mathbb{R}^{300}$, przy użyciu okna kontekstowego o rozmiarze 3 tokenów znakowych. Aby zapobiec niedotrenowaniu przyjmujemy 60 epok na korpusie, zachowując

minimalny próg wystąpień n -gramu na poziomie 1.

W celu osadzenia całych słów w_i w przestrzeni $\mathbb{R}^{300}$ wyznaczamy centroidy wszystkich 3-gramów wchodzących w skład słowa w_i . Centroid v_{w_i} wyznaczamy jako średnią arytmetyczną wektorów odpowiadających 3-gramom $g \in F_3(w_i)$ gdzie przez $F_n(w_i)$ rozumiemy multizbiór wszystkich n -gramów słowa w_i , a v_g jest wektorem odpowiadającym 3-gramowi g :

$$v_{w_i} = \frac{1}{|F_3(w_i)|} \sum_{g \in F_3(w_i)} v_g. \quad (1)$$

Analogicznie w celu osadzenia całego języka $\mathcal{L}$ w przestrzeni wektorowej $\mathbb{R}^{300}$ wyznaczamy centroid wszystkich wektorów v_{w_i} odpowiadających słowom $w_i \in \mathcal{L}$:

$$v_{\mathcal{L}} = \frac{1}{|\mathcal{L}|} \sum_{w_i \in \mathcal{L}} v_{w_i}. \quad (2)$$

Uśrednienie całego języka do pojedynczego wektora jest zabiegiem celowym. Ma to na celu wykazanie, że nawet przy maksymalnym uproszczeniu liczbowym, przy tak dużej utracie danych, model wciąż jest w stanie uchwycić różnice typologiczne.

Kolejnym krokiem jest wyznaczenie podobieństwa między językami. Niech $\mathcal{C}$ oznacza zbiór wszystkich 32 korpusów językowych. Dla każdej pary języków $(\mathcal{L}_1, \mathcal{L}_2) \in \mathcal{C} \times \mathcal{C}$ wyznaczamy podobieństwo cosinusowe S_C dane wzorem:

$$S_C(\mathcal{L}_1, \mathcal{L}_2) = \frac{v_{\mathcal{L}_1} \cdot v_{\mathcal{L}_2}}{\|v_{\mathcal{L}_1}\| \|v_{\mathcal{L}_2}\|}. \quad (3)$$

Wszystkie podobieństwa cosinusowe zbieramy w macierzy $\mathbf{M}$ o wymiarach $|\mathcal{C}| \times |\mathcal{C}|$, gdzie każdy i -ty wiersz i każda j -ta kolumna odpowiadają odpowiednio językom $\mathcal{L}_i, \mathcal{L}_j \in \mathcal{C}$, gdzie $i, j \in \{1, 2, \dots, |\mathcal{C}|\}$:

$$\mathbf{M} = [m_{ij}]_{|\mathcal{C}| \times |\mathcal{C}|}, \quad m_{ij} = S_C(\mathcal{L}_i, \mathcal{L}_j). \quad (4)$$

Po wyznaczeniu podobieństw S_C między językami możemy przejść do klasteryzacji ich w grupy językowe. W tym celu posłużymy się algorytmem Affinity Propagation [9]. W przeciwieństwie do klasycznych metod klasteryzacyjnych algorytm ten nie wymaga zdefiniowanej a priori liczby klastrów. Proces klasteryzacji opiera się na wymianie wiadomości między językami, aż do wyłonienia optymalnego zestawu egzemplarzy reprezentujących poszczególne podgrupy języków. Wartość parametru preferencji p ustalamy na $p = 0.9$. Dla mniejszych wartości p algorytm wpadał w nadmierną fragmentację, tworząc dużo pojedynczych klastrów, wartość $p = 0.9$ okazała się punktem stabilizacji modelu.

Po wyodrębnieniu klastrów $\mathcal{G}$, możemy przejść do przeprowadzenia ilościowej charakterystyki morfologicznej. Z dalszej analizy wykluczamy klastry jednoelementowe, które tworzą języki izolowane. Dodatkowo, w oparciu o dystrybucję skrajnych 3-gramów (zawierających markery granic słowa #), wyodrębniamy zbiory najczęściej występujących afiksów.

Niech $\mathcal{W}(\mathcal{G})$ oznacza multizbiór wszystkich słów w takich, że $w \in \mathcal{L}$ oraz $\mathcal{L} \in \mathcal{G}$. Długość pojedynczego słowa w będziemy oznaczać jako $|w|$. Średnią długość wszystkich słów $w \in \mathcal{W}(\mathcal{G})$ oznaczamy jako $\overline{|w|}$ i wyrażamy wzorem:

$$\overline{|w|} = \frac{1}{|\mathcal{W}(\mathcal{G})|} \sum_{w \in \mathcal{W}(\mathcal{G})} |w|. \quad (5)$$

Odchylenie standardowe długości słów $w \in \mathcal{W}(\mathcal{G})$ oznaczamy jako σ i definiujemy wzorem:

$$\sigma = \sqrt{\frac{1}{|\mathcal{W}(\mathcal{G})|} \sum_{w \in \mathcal{W}(\mathcal{G})} (|w| - \overline{|w|})^2}. \quad (6)$$

Niech $|w|_V$ oznacza liczbę samogłosek w słowie w , procentowy udział samogłosek w słowach $w \in \mathcal{W}(\mathcal{G})$ oznaczamy jako P_V i definiujemy wzorem:

$$P_V = \frac{\sum_{w \in \mathcal{W}(\mathcal{G})} |w|_V}{\sum_{w \in \mathcal{W}(\mathcal{G})} |w|} \cdot 100\%. \quad (7)$$

Niech $[w]_C$ oznacza maksymalną długość zbitki spółgłoskowej w słowie w , średnią maksymalną długość zbitki spółgłoskowej w słowach $w \in \mathcal{W}(\mathcal{G})$ oznaczamy jako $\overline{[w]}_C$ i definiujemy wzorem:

$$\overline{[w]}_C = \frac{1}{|\mathcal{W}(\mathcal{G})|} \sum_{w \in \mathcal{W}(\mathcal{G})} [w]_C. \quad (8)$$

Niech $G_2 = \biguplus_{w_i \in \mathcal{W}(\mathcal{G})} F_2(w_i)$ oznacza multizbiór wszystkich 2-gramów słów z multizbioru $\mathcal{W}(\mathcal{G})$. Entropię 2-gramową H_2 wyznaczamy zgodnie z następującym pseudokodem:

Algorithm 1: Obliczanie entropii 2-gramowej

Data: G_2 – multizbiór wszystkich 2-gramów dla danej grupy

Result: H_2 – entropia 2-gramowa wyrażona w bitach

```

1  $t \leftarrow |G_2|;$ 
2  $C \leftarrow \{\};$ 
3  $H_2 \leftarrow 0;$ 
4 foreach  $g \in G_2$  do
5   if  $g \in C$  then
6      $C[g] \leftarrow C[g] + 1;$ 
7   else
8      $C[g] \leftarrow 1;$ 
9 foreach  $c \in \text{values}(C)$  do
10    $p \leftarrow c/t;$ 
11   if  $p > 0$  then
12      $H_2 \leftarrow H_2 - p \cdot \log_2(p);$ 
13 return  $H_2;$ 
```

Proces wektoryzacji zrealizowano z wykorzystaniem biblioteki `Gensim` w środowisku Python, natomiast do klasteryzacji użyto implementacji algorytmu Affinity Propagation z pakietu `scikit-learn`.

3. Eksperymenty

3.1. Materiał Badawczy

Materiał poddany analizie składał się z 32 korpusów językowych. Dla każdego z języków wybrano 15 000 najczęściej występujących słów alfabetu łacińskiego, pozyskanych z bazy OpenSubtitles [10]. Zestawienie wszystkich analizowanych języków zebrano w tabeli 1. Wybór był podyktowany dążeniem do analizowania naturalnego, potocznego języka, występującego w mowie codziennej, a nie bardziej oficjalnej mowy literackiej.

Table 1

Zestawienie 32 języków uwzględnionych w badaniu.

Albanian	Basque	Bosnian	Catalan
Croatian	Czech	Danish	Dutch
English	Estonian	Finnish	French
Galician	German	Hungarian	Icelandic
Indonesian	Italian	Latvian	Lithuanian
Malay	Norwegian	Polish	Portuguese
Romanian	Serbian	Slovak	Slovenian
Spanish	Swedish	Turkish	Vietnamese

3.2. Sieć Podobieństwa Języków

Pierwszym wynikiem badań była macierz podobieństwa języków $\mathbf{M}$, która została przedstawiona za pomocą mapy ciepła na rysunku 1. Macierz $\mathbf{M}$ została zwizualizowana także za pomocą grafu nieskierowanego, przedstawionego na rysunku 2. Jako wierzchołki grafu przyjęto zbiór wszystkich języków $\mathcal{C}$, a krawędź między językami $\mathcal{L}_1, \mathcal{L}_2$ istnieje, jeżeli $S_C(\mathcal{L}_1, \mathcal{L}_2) \geq 0.96$.

Analiza wygenerowanego grafu ujawniła powstanie dwóch wyraźnych skupisk, które z dużą dokładnością pokrywają się z istniejącymi grupami językowymi. W lewej stronie rysunku 2 można zauważyć duży klaster, odpowiadający językom romańsko-germańskim, natomiast po prawej powstał klaster odpowiadający językom bałkańsko-środkowoeuropejskim. Graf poprawnie wykazuje także podobieństwo języków austronezyjskich (indonezyjski i malajski) oraz języków bałtycko-fińskich (estoński i fiński).

3.3. Typologiczne Klastrowanie Języków

Następnym krokiem było wykorzystanie macierzy $\mathbf{M}$, do klastrowania języków. Do klasteryzacji został wykorzystany algorytm Affinity Propagation [9], który dokonuje klasteryzacji bez podania a priori liczby klastrów, pozwala to na naturalne odzwierciedlenie grup językowych, bez sztucznego ustawiania liczby klastrów. W wyniku działania algorytmu zostało utworzonych 6 klastrów, które zebrane zostały w tabeli 2. Pozostałe języki, ze względu na ich unikalną morfologię, zostały potraktowane jako języki izolowane.

Algorytm Affinity Propagation poprawnie sklasteryzował języki $\mathcal{L} \in \mathcal{C}$, wiernie odzwierciedlając istniejące grupy językowe. Grupa {Bosnian, Croatian, Serbian, Slovenian} odzwierciedla grupę języków południowosłowiańskich, a grupa {Czech, Slovak} odpowiada grupie




Figure 1: Mapa korelacji języków będąca graficzną reprezentacją macierzy M

języków zachodniosłowiańskich [11]. Warto zaznaczyć, że język polski, mimo genealogicznego pokrewieństwa z językiem czeskim i słowackim, nie należy do tej grupy. Wynika to z unikalnej ortografii języka polskiego. Dźwięki, które w czeskim i słowackim zapisane zostaną z diakrytykami (np. š, č), w języku polskim reprezentowane są przez dwuznaki (np. sz, cz) [12]. Grupa {Estonian, Finnish} odpowiada grupie bałtycko-fińskiej [13], z kolei grupa {Indonesian, Malay} jest odzwierciedleniem grupy malajskiej [14]. Grupa {Danish, Dutch, German, Norwegian, Swedish} odpowiada zarówno grupie germańskiej jak i skandynawskiej, co jest skutkiem dużego morfologicznego podobieństwa tych grup, spowodowanego latami handlu między ludnością, co prowokowało naturalną transformację języków w stronę większej unifikacji [15].

Ostatnią grupą jest {Catalan, English, French, Galician, Italian, Portuguese, Romanian, Spanish}, odpowiada ona grupie języków romańskich. Zakwalifikowanie języka angielskiego do języków romańskich może wydawać się błędem, jednak mimo odmiennej genealogii, wpływ języków romańskich na język angielski w istotny sposób zmienił morfologię angielskiego,




Figure 2: Graf wygenerowany na podstawie macierzy $\mathbf{M}$ z progiem $S_C > 0.96$

skutecznie upodabniając go strukturalnie do innych języków romańskich [16]. Przy korpusie 15 000 tokenów ponad 50% angielskiego słownictwa jest pochodzenia łacińskiego i francuskiego, co zdecydowanie przeważa nad słowami pochodzenia germańskiego (około 26%) [17]. Przykład ten pokazuje dużą skuteczność algorytmu, który mimo odmiennych pochodzeń języków potrafi wskazać ich wzajemny wpływ na siebie.

Table 2

Klasy powstałe w wyniku działania algorytmu Affinity Propagation.

Lider grupy $\mathcal{G}$	Członkowie grupy
Bosnian	Bosnian, Croatian, Serbian, Slovenian
Catalan	Catalan, English, French, Galician, Italian, Portuguese, Romanian, Spanish
Czech	Czech, Slovak
Estonian	Estonian, Finnish
Indonesian	Indonesian, Malay
Danish	Danish, Dutch, German, Norwegian, Swedish

3.4. Ilościowa Analiza Morfologiczna

Ostatnim krokiem badań było wyekstrahowanie ilościowych danych morfologicznych z każdej z sześciu grup językowych. Charakterystyka morfologiczna została wyznaczona zgodnie ze wzorami (5–8) oraz Algorytmem 1. Pełna charakterystyka, dla każdej z sześciu grup została zebrana w Tabeli 3.

Table 3

Charakterystyka morfologiczna wyodrębnionych klastrów.

Lider grupy $\mathcal{G}$	$ \mathcal{G} $	$ \overline{w} $	σ	P_V [%]	$ \overline{w} _C$	H_2 [bit]
Bosnian	4	6.43	1.99	42.30	1.78	7.82
Catalan	8	6.88	2.26	43.30	1.79	7.86
Czech	2	6.38	1.96	41.50	1.79	8.52
Estonian	2	7.05	2.21	46.20	1.67	7.70
Indonesian	2	6.92	2.56	42.30	1.69	7.34
Danish	5	6.85	2.50	37.40	2.02	7.95

Analiza uzyskanych danych potwierdza istotną odmienność między klastrami. Grupy wykazujące się najwyższą entropią 2-gramową H_2 , takie jak klaster czeski ($H_2 = 8.52$ bit) czy duński ($H_2 = 7.96$ bit), odznaczają się wysoką złożonością budowy słowa oraz częstotliwością występowania rzadkich połączeń znakowych. Znajduje to bezpośrednie odzwierciedlenie w wartościach średniej maksymalnej długości zbitki spółgłoskowej $|\overline{w}|_C$, która osiąga najwyższą wartość ($|\overline{w}|_C = 2.02$) właśnie dla klastra duńskiego. Z kolei klastry o niższej entropii 2-gramowej H_2 , takie jak klaster estoński czy indonezyjski odznaczają się większym procentowym rozkładem samogłosek P_V , który wartość największą ($P_V = 46.20$ %) przyjmuje dla klastra estońskiego.

Ostatnim elementem ilościowej analizy utworzonych grup było wyodrębnienie najczęściej występujących afiksów, w każdej grupie. W tym celu przeprowadzono analizę najczęściej występujących skrajnych 3-gramów (zawierających markery granic słowa). Wyniki tej analizy dla poszczególnych grup zestawiono w Tabeli 4.

Jak pokazuje powyższa tabela algorytm poprawnie rozpoznał afiksy dla wyznaczonych grup językowych. Klaster indonezyjski odzwierciedla afiksy języków austronezyjskich [18], z kolei sufiksy takie jak *-es*, *-os* czy *-as* w klastrze katalońskim odpowiadają bezpośrednio końcówkom liczby mnogiej w językach romańskich, takich jak hiszpański [19]. Prefiksy klastra

Table 4

Najczęstsze afiksy dla wyodrębnionych klastrów językowych.

Lider grupy $\mathcal{G}$	Top 5 początkowych 2-gramów	Top 5 końcowych 2-gramów
Bosnian	<i>po-, pr-, na-, za-, do-</i>	<i>-ti, -la, -te, -je, -na</i>
Catalan	<i>co-, re-, pr-, de-, ca-</i>	<i>-es, -os, -te, -er, -as</i>
Czech	<i>ne-, po-, pr-, za-, vy-</i>	<i>-te, -la, -li, -ní, -ie</i>
Estonian	<i>va-, ka-, ta-, ko-, pa-</i>	<i>-in, -ta, -an, -en, -si</i>
Indonesian	<i>me-, pe-, be-, di-, ke-</i>	<i>-an, -ya, -ng, -ah, -mu</i>
Danish	<i>be-, st-, ve-, ge-, ma-</i>	<i>-en, -er, -et, -de, -te</i>

bośniackiego i czeskiego odzwierciedlają najczęściej występujące prefiksy języków słowiańskich [20], natomiast afiksy klastra duńskiego pochodzą bezpośrednio od odmiany czasowników [21]. Języki estońskie nie posiadają klasycznych prefiksów, związanych ze słowotwórstwem [22], z tego powodu algorytm wyłapał najczęściej powtarzające się rdzenie słowotwórcze *ka-*, *ta-* pochodzące od słów takich jak *kas*, *tahan*.

4. Podsumowanie

Praca miała na celu zbadać, czy wykorzystanie prostego algorytmu opartego na wektoryzacji 3-gramów z wykorzystaniem algorytmu Word2Vec oraz Affinity Propagation będzie w stanie poprawnie odzwierciedlić rodziny językowe.

Jak pokazała analiza danych, algorytm poprawnie odtworzył rodziny romańskie, germańskie, słowiańskie i austronezyjskie operując wyłącznie na surowym tekście, bez dostępu do zewnętrznych słowników. Model trafnie wyłapał różnice ortograficzne, leksykalne i morfologiczne – między innymi wyodrębnił najczęściej występujące afiksy dla utworzonych grup językowych, które odpowiadają rzeczywistym afiksom wybranych rodzin. Kolejnym efektem badania było wyznaczenie charakterystyk zebranych w Tabeli 3, które zawierają zestawienie kluczowych cech każdej z grup językowych.

Jedną z głównych wad modelu jest fakt, że stosowanie surowego tekstu, zamiast transkrypcji fonetycznej powoduje dużą wrażliwość na lokalne cechy zapisu (nierozpoznanie języka polskiego, jako należącego do wspólnej grupy z czeskim i słowackim). Duży wzajemny wpływ wybranych języków może powodować (tak jak w języku angielskim), że mimo odmiennego pochodzenia genealogicznego, leksyka języków zmieni się na tyle, że algorytm nie będzie w stanie odseparować dwóch języków, o różnych pochodzeniach.

Zebrane charakterystyki mogą być podstawą do dalszych badań. Bazując na skuteczności zaproponowanego algorytmu, obiecującym kierunkiem dalszego rozwoju byłoby rozszerzenie analizy o języki posługujące się innymi systemami pisma (np. cyrylicą, greką czy alfabetem arabskim), a także zbadanie jak rozmiar korpusu wpływa na wyniki końcowe.

References

- [1] B. Stevens, Aeolism: Latin as a dialect of greek, *The classical journal* 102 (2007) 115–144.

- [2] S. Botterill, et al., *Dante: De vulgari eloquentia*, volume 5, Cambridge University Press, 1996.
- [3] R. H. Robins, *A short history of linguistics*, Routledge, 2013.
- [4] M. Serva, F. Petroni, Indo-european languages tree by levenshtein distance, *EPL (Euro-physics Letters)* 81 (2008) 68005.
- [5] A. K. Jain, Data clustering: 50 years beyond k-means, *Pattern Recognition Letters* 31 (2010) 651–666. URL: <https://www.sciencedirect.com/science/article/pii/S0167865509002323>. doi:<https://doi.org/10.1016/j.patrec.2009.09.011>, award winning papers from the 19th International Conference on Pattern Recognition (ICPR).
- [6] A. Virtanen, J. Kanerva, R. Ilo, J. Luoma, J. Luotolahti, T. Salakoski, F. Ginter, S. Pyysalo, Multilingual is not enough: Bert for finnish, *arXiv preprint arXiv:1912.07076* (2019).
- [7] P. Bojanowski, E. Grave, A. Joulin, T. Mikolov, Enriching word vectors with subword information, *Transactions of the association for computational linguistics* 5 (2017) 135–146.
- [8] T. Mikolov, K. Chen, G. Corrado, J. Dean, Efficient estimation of word representations in vector space, *arXiv preprint arXiv:1301.3781* (2013).
- [9] B. J. Frey, D. Dueck, Clustering by passing messages between data points, *science* 315 (2007) 972–976.
- [10] P. Lison, J. Tiedemann, M. Kouylekov, Opensubtitles2018: Statistical rescoring of sentence alignments in large, noisy parallel corpora, in: *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*, 2018.
- [11] G. Corbett, B. Comrie, *The slavonic languages*, Routledge, 2003.
- [12] E. Gussmann, *The phonology of Polish*, OUP Oxford, 2007.
- [13] D. Abondolo, *The Uralic languages*, Routledge, 2015.
- [14] K. A. Adelaar, N. Himmelmann, *The austronesian languages of asia and madagascar*, Routledge, 2004.
- [15] E. Haugen, *The Scandinavian Languages: An Introduction to Their History*, Harvard University Press, Cambridge, MA, 1976.
- [16] A. C. Baugh, T. Cable, *A history of the English language*, Routledge, 1993.
- [17] T. Finkenstaedt, D. Wolff, *Ordered profusion: Studies in dictionaries and the english lexicon* (1973).
- [18] A. Purwarianti, A non deterministic indonesian stemmer, 2011, pp. 1–5. doi:10.1109/ICEEI.2011.6021829.
- [19] C. Lleo, Early acquisition of nominal plural in spanish, *Catalan Journal of Linguistics* 5 (2006) 191. doi:10.5565/rev/catjl.69.
- [20] H. Filip, The relation of slavic verb prefixes to perfective aspect, *Languages* 11 (2025) 5.
- [21] T. Lundskaer-Nielsen, P. Holmes, *Danish: A comprehensive grammar*, Routledge, 2015.
- [22] I. Tälberga, Estonian equivalents of the latvian verb prefix aiz, *Valoda: nozīme un forma* (2017) 232–243.